Pandas Veri Analizi (Panel Data)

Numpy bazı özellikleri itibari ile yetersiz kalmaktadır. Numpy üzerinde vektörel işlemleri(matematiksel ve istatistiksel) kolaylıkla yapabiliyorduk. Ancak veri analitiği, veri işleme ve veri madenciliği konularında yetersiz kalmaktadır. Numpy'de veri tiplerinin tek tipte olması gerekiyordu. Farklı türde veriler üzerinde işlem yapılmak istendiğinde pandas bu işlevi çok iyi bir şekilde karşılayacaktır. Yapılacak modelleme işlemleri pandas ile yapılmaktadır. Pandas, numpy kütüphanesinin bir alternatifi değildir. numpy özelliklerini kullanır ve bunları genişletir. Numpy dizilerine array(vektör ve matrisler) diyorduk, pandas dizileri ise tek boyutlu olanları seriler(series) iki boyutlu olanlar ilse Veri Çerçeveleri(DataFrames) olarak adlandırılır.

Pandas kütüphanesi veri analizi için yazılmış bir python kütüphanesidir. 2008 yılında geliştirilmeye başlanmıştır. Farklı veri tipleri ile çalışılabilir. Numpy arraylarinden en belirgin farkı sütunlar isimlendirilebilir, satır indis numaraları değiştirilebilir, farklı veri tiplerini içerisinde barındırabilir.

Pandas kütüphanesini projemize dahil etmek için

import pandas as pd

komutu kullanılmalıdır. Ancak pandas kütüphanesi ile beraber numpy kütüphanesinin de mutlaka projeye dahil edilmesi gerekmektedir. Çünkü kullanacağımız pandas serilerini genellikle numy array'lerinden üretmeye çalışacağız.

Pandas Serisi Oluşturma

Pandas serileri oluştururken veriler üzerinden, python dizilerinden ya da numpy array'lerinden faydalanabiliriz. Bir pandas seri'si oluşturmak için
pd.Series(["data"],["index"])
şeklinde bir tanımlama yapmak gerekmektedir. index değerleri verilmezse otomatik olarak 0,1,2 şeklinde indis değerleri atanacaktır.

pd.Series([1,2,3,4,5,6])

```
0    1
1    2
2    3
3    4
4    5
5    6
dtype: int64
```

yöntemini kullanabiliriz. Dikkat edileceği üzere aynı numpy arraylerini oluşturduğumuz gibi iç içe hem normal parantez hem de köşeli parantezi beraber kullandık. Aksi halde hata ile karşılaşacaktık. Ayrıca oluşturulan seri'nin altında veri tipi de(int 64) yazmaktadır.

pd.Series(1,2,3,4,5,6)

```
---------------------------------------------------------------------------
TypeError                                 Traceback (most recent call last)
<ipython-input-61-8a1ca8fd665e> in <module>
----> 1 pd.Series(1,2,3,4,5,6)

~\Anaconda3\lib\site-packages\pandas\core\series.py in __init__(self, data, index, dtype, name, copy, fastpath)
    201         # we are called internally, so short-circuit
    202         if fastpath:
--> 203
    204             # data is an ndarray, index is defined
    205             if not isinstance(data, SingleBlockManager):

~\Anaconda3\lib\site-packages\pandas\core\internals\managers.py in __init__(self, block, axis, do_integrity_check, fastpath)
   1514
   1515         if not isinstance(block, Block):
-> 1516             block = make_block(block, placement=slice(0, len(axis)), ndim=1)
   1517
   1518         self.blocks = tuple([block])

TypeError: object of type 'int' has no len()
```

Yine numpy'de olduğu gibi ([]) parantez köşeli parantez yapısıyla beraber iç içe iki parantez (()) yapısı kullanılarak da pandas seri'si oluşturulabilir.
Serileri oluştururken sadece sayısal değerler değil string ifadelerden de faydalanabiliriz.

seri=pd.Series(["ankara","istanbul","izmir","antalya","bursa"])

seri

```
0       ankara
1     istanbul
2        izmir
3      antalya
4        bursa
dtype: object
```

Liste üzerinden Seri Oluşturma

Pythonda oluşturduğumuz listeleri bir pandas serisine dönüştürebiliriz. Normalde python listelerinin indis numaraları vardır ancak bunları listeleme işlemi yaptığımızda göremeyiz. Listeyi seri'ye dönüştürdüğümüzde ise indis değerleri listeyle beraber görülecektir.

liste=[1,2,3,4,5,6]

seri=pd.Series(liste)

seri

```
0    1
1    2
2    3
3    4
4    5
5    6
dtype: int64
```

görüldüğü üzere seri elemanları ile beraber indis değerleri de listelenmiştir.
Liste veri tipi zaten köşeli parantez içerdiği için ayrıca iç içe parantez köşeli parantez yapısı kullanmaya gerek yoktur.

Numpy Array'i Üzerinden Seri Oluşturma İşlemi

Bir array üzerinden seri oluşturmak için tıpkı listelerde yaptığımız işlem gibi önce array oluşturup array üzerinden seri oluşturma işlemi yapabiliriz.

a=np.arange(1,6)

seri=pd.Series(a)

seri

```
0    1
1    2
2    3
```

```
3    4
4    5
dtype: int32
```

Biçimlendirme İşlemleri

Oluşturduğumuz pandas seri'lerinin **type** fonksiyonu ile yapısına bakmak istersek,

seri = pd.Series([1,2,3,4,5,6])

type(seri)

```
pandas.core.series.Series
```

şeklinde bir veri tipine ait olduğunu görebiliriz.

Hatırlanacağı üzere numpy'de array ile ilgili özelliklere dtype(veri tipi), ndim(boyut sayısı), shape(boyut bilgisi) ve size(eleman sayısı) methodları ile yapıyorduk. Pandas'ta bu işlemi yapmak için de benzer metodlar kullanabilriz.

- axes metodu seri'nin özellikleri görüntülenebilir.

seri.axes

```
[RangeIndex(start=0, stop=6, step=1)]
```

Görüldüğü üzere axes metodu ile başlangıç, bitiş ve atlama değerine ulaşmış olduk.

Seri içersindenki değerlerin veri tipini öğrenmek istesek

seri.dtype

```
dtype('int64')
```

seri'nin kaç boyutlu olduğunu öğrenmek istersek ndim metodu kullanabiliriz.

seri.ndim

```
1
```

Eleman sayısına ulaşmak için size metodu kullanılabilir.

seri.size

```
6
```

Shape meto ile boyut bilgisine ulaşabiliriz.

seri.shape

```
(6,)
```

Seri üzerindeki değerleri indislerden bağımsız görüntülemek istersek values parametresi kullanlmalıyız.

seri.values

```
y([1, 2, 3, 4, 5, 6], dtype=int64)
```

head metodu sayesinde en baştan istediğimiz kadar değer görüntüleyebiliriz.

seri.head(2)

```
0    1
1    2
dtype: int64
```

tail metodu ile sondan istediğimiz kadar değer görüntüleyebiliriz.

seri.tail(3)

```
3    4
4    5
5    6
dtype: int64
```

eğer head ve tail fonksiyonlarına parametre verilmezse ilk 5 ya da son 5 değeri verir.

seri.head()

```
0    1
1    2
2    3
```

```
3    4
4    5
dtype: int64
```

Seriler Üzerinde İndeksleme işlemleri

Array'lar üzerinde yaptığımız indexleme işlemlerini seri'ler üzerinde de yapabiliriz.

seri=pd.Series([1,2,3,4,5,6])

seri[0]

```
1
```

seri[3]

```
4
```

Seri'lerde index değerlerini değiştirme

Pandas seri'lerinde index'lerin değerini değiştirerek istediğimiz değerleri atayabiliyoruz. Normalde biz değer vermediğmizde index değerleri otomatik olarak indis(0,1,2..) değerlerine karşılık gelmektedir.

seri=pd.Series((1,2,3,4,5),index=(0,2,4,6,8))

seri

```
0    1
2    2
4    3
6    4
8    5
dtype: int64
```

pandas'ta yapacağımız index'leme sadece integer ifadelerle sınırlı değil float hatta string değerlerle bile index'leme işlemi yapılabilir.

seri=pd.Series((1,2,3,4,5),index=("a","b","c","d","e"))

seri

```
a    1
b    2
c    3
d    4
e    5
dtype: int64
```

hatırlanacağı üzere pandas serilerinin sözlük yapılarına benzediğini söylemiştik. Aynı sözlüklerdeki gibi elemanlara erişim işlemleri yapabiliriz.

seri["b"]

```
2
```

Seri'lerin index değerlerini string değerlerle değiştirmiş olsak bile indis değerleri üzerinden elemanlarına erişebiliriz.

seri[0]

```
1
```

seri[2]

```
3
```

Ancak bu işlemi indis değerlerini string olarak tanımladığımız zaman gerçekleştirebiliriz.

seri=pd.Series((1,2,3,4,5),index=(10,20,30,40,50))

seri[1]

```
---------------------------------------------------------------------------
KeyError                                  Traceback (most recent call last)
<ipython-input-25-1f5676597884> in <module>
----> 1 seri[1]

~\Anaconda3\lib\site-packages\pandas\core\series.py in __getitem__(self, key)
   1069         key = com.apply_if_callable(key, self)
   1070         try:
-> 1071             result = self.index.get_value(self, key)
   1072
   1073             if not is_scalar(result):
```

Resim 88

Bunun için ileride edetaylı deyineceğimiz loc ve iloc metodlarını kullanacağız.

Sözlükler Üzerinden Seri Oluşturma İşlemleri

Pandas serileri oluştururken sözlükler üzerinden seri oluşturma işlemleri sıkça kullanılmaktadır.

sozluk={"a":1,"b":2,"c":3,"d":4,"e":5}

sozluk

```
{'a': 1, 'b': 2, 'c': 3, 'd': 4, 'e': 5}
```

seri=pd.Series(sozluk)

seri

```
a    1
b    2
c    3
d    4
e    5
dtype: int64
```

yine elemanlara ulaşmak istediğimizde index değerlerini yazmamız yeterlidir.

seri["a"]

```
1
```

Seri'lere Erişim İşlemleri

Seri'ler yapı itibariyle sözlükleri andırmaktadır. Hem index değerlerine hem de elemanlarına ulaşabiliriz. Elemanlarına ulaşmak için values metodu kullanabiliriz.

seri=pd.Series([1,2,3,4,5,6]

seri.values

```
array([1, 2, 3, 4, 5, 6], dtype=int64)
```

index'lerine ulaşmak için ise index metodunu kullanabiliriz.

seri.index

```
RangeIndex(start=0, stop=6, step=1)
```

Seri içerisindeki index ve değerlere ulaşabilmek için items metodu kullanılmalıdır.

seri.items

```
<bound method Series.items of 0    1
1    2
2    3
3    4
4    5
5    6
dtype: int32>
```

Seri'lerde Dilimleme İşlemleri

Dilimleme işlemleri yapmak istersek aynı şekilde : işareti ile başlangıç ve bitiş index isimlerini yazmamız yeterlidir.

a=pd.Series([1,2,3,4,5,6])

a

```
0    1
1    2
2    3
3    4
4    5
5    6
dtype: int64
```

burada dilimleme işlemi yapmak istersek

a[0:3]

```
0    1
1    2
2    3
dtype: int64
```

klasik dilimleme işlemlerindeki gibi başlangıç değerlerini aldı ancak bitiş değerini almadı. Şimdi seri'nin index değerlerini değiştirelim. Eğer serilerde index değerlerini farklı sayısal ifadelerle değiştirirsek, dilimleme işlemi yapmak istediğimizde boş değer döner.

a.index=(10,20,30,40,50,60)

a[10:50]

```
Series([], dtype: int64)
```

Bu durumda ileride daha detaylı göreceğimiz loc metodunu kullanmalıyız.

index değerine sayısal ifade değil de string değerler verirsek, dilimleme işlemini index değerlerine göre yapabiliriz.

a.index=("a","b","c","d","e","f")

seri["a":"d"]

```
a    1
b    2
c    3
d    4
dtype: int64
```

python ve numpy array'leri kullanırken dilimleme işlemleri yaptığımızda hatırlanacağı üzere başlangıç değeri alınıp bitiş değeri alınmıyordu, pandas'da ise indislerini değiştirdiğimiz serilerin son değeri de listelenmektedir. Yukarıda her iki örnekte de görüleceği üzere seri[10:50] işleminde "50" index değerine karşılık gelen değer, **seri["a":"d"]** işleminde de normalde biz **"d"** indexine karışık gelen değeri almayacağını beklerdik ancak burada değerin alındığını görmekteyiz.

Eğer indis değerlerinden erişmek istersek

a[0:3]

seri[0:3]

```
a    1
b    2
c    3
dtype: int64
```

görüldüğü üzere indis değerlerine göre dilimleme yapmak istersek alışık olduğumuz şekilde son değeri almayacaktır.

Seri'lerde Birleştirme İşlemleri

Birden fazla seriyi birleştirme işlemi yapabiliriz. Numpy'de array'leri birleştirmek için "**concatenate**" metodunu kullanıyorduk. Pandas'da ise bunun yerine "concat" metdou kullanılabilir.

```
seri1=pd.Series((1,2,3,4),index=("a","b","c","d"))
seri2=pd.Series((5,6,7,8),index=("e","f","g","f"))
pd.concat([seri1,seri2])
```

```
a    1
b    2
c    3
d    4
e    5
f    6
g    7
f    8
dtype: int64
```

ya da listelerde kullandığımız append metodunu kullanabiliriz.

```
seri1.append(seri2)
```

```
a    1
b    2
c    3
d    4
e    5
f    6
g    7
f    8
dtype: int64
```

Seri'lerde Eleman İşlemleri

Python'da bir değerin ya da ifadenin liste ya da karakter dizisi içerisinde olup olmadığını kontrol etmek için in operatörünü kullanıyorduk. Aynı şekilde bir değerin seri içerisinde olup olmadığını da in işleci ile kontrol edebiliriz. Burada yapılan kontrol index değerleri üzerinden yapılmaktadır.

```
seri1=pd.Series((1,2,3,4),index=("a","b","c","d"))
"a" in seri1
```

```
True
```

```
"e" in seri1
```

```
False
```

Eğer seride bulunan değeri değiştirmek istersek,

```
seri1["a"]=5
seri1
```

```
a    5
b    2
c    3
d    4
dtype: int64
```

sözlüklerde uyguladığımız metodu kullanabiliriz.

Seriler üzerinde erişim işlemlerini önceki bölümlerde görmüştük. Dilimleme işlemleri yaparken eğer index isimleri string ya da karakterlerden oluşacak şekilde değiştirildiyse yeni oluşturduğumuz index isimlerine göre değerlere erişebiliyorduk. Ancak 0,1,2 şeklinde indis değerleri görülmese de seri içerisinde bulunmaktadır.

```
seri[0]
```

```
1
```

```
seri[1]
```

```
2
```
İndex değerlerini değiştirdiğimiz serilere indis değerleri üzerinden dilimleme işlemi yaparsak alışık old uğumuz üzere yazdığımız son değer alınmamaktadır.

seri[0:3]

```
0    1
1    2
2    3
dtype: int64
```

<u>ancak index değerlerini string değil integer ifadeler olarak belirlediysek artık yeni indis değerleri bu verdiğimiz ifadeler olur ve bu şekilde indis değerlerine ulaşmak mümkün değildir.</u>

seri2=pd.Series((1,2,3,4),index=(10,20,30,40))

seri2[0]

```
KeyError                                  Traceback (most recent call last)
<ipython-input-56-8793667b7c12> in <module>
----> 1 seri2[0]

~\Anaconda3\lib\site-packages\pandas\core\series.py in __getitem__(self, key)
   1069         key = com.apply_if_callable(key, self)
   1070         try:
-> 1071             result = self.index.get_value(self, key)
   1072
   1073             if not is_scalar(result):

~\Anaconda3\lib\site-packages\pandas\core\indexes\base.py in get_value(self, series, key)
   4728         k = self._convert_scalar_indexer(k, kind="getitem")
   4729         try:
-> 4730             return self._engine.get_value(s, k, tz=getattr(series.dtype, "tz", None))
   4731         except KeyError as e1:
   4732             if len(self) > 0 and (self.holds_integer() or self.is_boolean()):

pandas/_libs/index.pyx in pandas._libs.index.IndexEngine.get_value()

pandas/_libs/index.pyx in pandas._libs.index.IndexEngine.get_value()

pandas/_libs/index.pyx in pandas._libs.index.IndexEngine.get_loc()

pandas/_libs/hashtable_class_helper.pxi in pandas._libs.hashtable.Int64HashTable.get_item()

pandas/_libs/hashtable_class_helper.pxi in pandas._libs.hashtable.Int64HashTable.get_item()

KeyError: 0
```

Bizim elemanlara erişmemiz için verdiğimiz index değerlerini yazmamız gerekmektedir. Yani index'in tanımlandığı şekliyle çağırılması gerekmektedir.

seri2[10]

```
1
```

Aynı şekilde dilimleme yapmak istersek hata ile karşılaşmayız ancak geriye boş değer döner..

seri2[10:30]

```
Series([], dtype: int64)
```

Görüldüğü üzere dilimleme işlemini yapamadık. Oysaki seri2[10] şeklinde index değeri yazdığımızda ilgili elemana ulaşabiliyorduk. Pandas üzerinde değiştirilmiş index değerine ulaşma ve dilimle işlemleri bu yüzden farklı metodlarla yapılmaktadır. Eğer serimizi elemanlarına dilimleme işlemleri uygulamak istersek index değerleri üzerinden değil indis değerleri üzerinden erişmemiz gerekmektedir.

seri2[0:2]

```
10    1
20    2
dtype: int64
```

loc Metodu

index değerleri değiştirdiğimiz ve sayısal ifade yaptığımız serilerde erişim ve dilimleme işlemlerini index numaraları üzerinden yapmak istersek loc(label based indexing) metodunu kullanmamız gerekmektedir. loc metodu serilerde eleman özelliklerine erişmek istediğimizde, değerin tanımlanmış şekliyle erişmemizi sağlamaktadır. Eğer index değerlerini değiştirerek indis değerleri üzerinden erişmek istersek hata ile karşılaşırız.

seri2=pd.Series((1,2,3,4),index=(10,20,30,40))

seri2[0]

```
KeyError                                  Traceback (most recent call last)
<ipython-input-67-8793667b7c12> in <module>
----> 1 seri2[0]

~\Anaconda3\lib\site-packages\pandas\core\series.py in __getitem__(self, key)
   1069         key = com.apply_if_callable(key, self)
   1070         try:
-> 1071             result = self.index.get_value(self, key)
   1072
   1073             if not is_scalar(result):

~\Anaconda3\lib\site-packages\pandas\core\indexes\base.py in get_value(self, series, key)
   4728         k = self._convert_scalar_indexer(k, kind="getitem")
   4729         try:
-> 4730             return self._engine.get_value(s, k, tz=getattr(series.dtype, "tz", None))
   4731         except KeyError as e1:
   4732             if len(self) > 0 and (self.holds_integer() or self.is_boolean()):

pandas/_libs/index.pyx in pandas._libs.index.IndexEngine.get_value()

pandas/_libs/index.pyx in pandas._libs.index.IndexEngine.get_value()

pandas/_libs/index.pyx in pandas._libs.index.IndexEngine.get_loc()

pandas/_libs/hashtable_class_helper.pxi in pandas._libs.hashtable.Int64HashTable.get_item()

pandas/_libs/hashtable_class_helper.pxi in pandas._libs.hashtable.Int64HashTable.get_item()

KeyError: 0
```

Bu durumda yeni index değerini yazarak klasik metod ile ya da loc ifadesi ile değerlere ulaşabiliriz

seri2.loc[10]

```
1
```

seri2[10]

```
1
```

Dilimle işlemi yaparken de loc metodu kullanmazsak geriye boş değer dönderir

seri2[10:30]

```
Series([], dtype: int64)
```

Bu durumda yine loc ifadesini kullanmalıyız

seri2.loc[10:30]

```
10    1
20    2
30    3
dtype: int64
```

dikkat edilirse dilimleme işleminde verilen son değer de alınmıştır. loc metodu kullanırken index değerleri tanımlandığı şekilde çağırıldığı için dilimleme işleminde index'te olmayan aralık belirtilse bile hata ile karşılaşılmaz.

seri2.loc[10:90]

```
10    1
20    2
30    3
```

```
40    4
dtype: int64
```

iloc metodu

iloc metodu loc metodunun tam tersi işlem yapmaktadır. Seri'nin elemanlarına verdiğimiz indis değerlerini dikkate almadan ulaşmak istersek

seri2=pd.Series((1,2,3,4),index=(10,20,30,40))
seri2.iloc[1]

```
2
```

İloc metodu ile verdiğimiz index değerlerine göre ulaşmak istersek hata ile karşılaşırız. Dilimleme işlemlerini yaparken index değerlerinin dikkate alınmadan indis değerleri üzerinden yapılmasını istersek iloc metodunu kullanmalıyız.

seri2=pd.Series((1,2,3,4),index=(10,20,30,40))
seri2.iloc[0:2]

```
10    1
20    2
dtype: int64
```

normal kullandığımız dilimleme metodu iloc metodu ile aynı işlemi yapmaktadır.

seri2[0:2]

```
10    1
20    2
dtype: int64
```

Serilerde Koşullu İşlemler

Array'lerde olduğu gibi seriler üzerinde de koşullu işlemler yapılabilmektedir.

seri1=pd.Series((10,20,30,40,50,60))
seri1>30

```
0    False
1    False
2    False
3     True
4     True
5     True
dtype: bool
```

görüldüğü üzere koşulu sağlayan değerler True, sağlamayan değerler ise False değeri almaktadır. Koşulu sağlayan elemanlara ulaşmak istersek,

seri1[seri1>30]

```
3    40
4    50
5    60
dtype: int64
```

şeklinde bir metod kullanılabilir.

Birden fazla koşulu sorgulamak istersek

seri1[(seri1>15) & (seri1<45)]

```
1    20
2    30
3    40
dtype: int64
```

Serilerde Aritmetiksel İşlemler

Array'lerde yaptığımız gibi Seri'lerle de basit aritmetiksel işlemler yapabiliriz.

```
seri=pd.Series((1,2,3,4))
seri+5
0    6
1    7
2    8
3    9
dtype: int64
seri*2
0    2
1    4
2    6
3    8
dtype: int64
```

İki farklı seri üzerinde temel aritmetiksel işlemleri gerçekleştirebiliriz. Elimizde aynı meyvelerden değişik kilolarda olduğunu varsayarak bir seri oluşturalım.

```
seri1=pd.Series([4,2,6,8,5],index=("elma","armut","üzüm","çilek","erik"))
seri2=pd.Series([5,6,1,3,7],index=("üzüm","elma","armut","erik","çilek"))
seri1+seri2
elma      9
armut     8
üzüm      7
çilek    11
erik     12
dtype: int64
```

görüldüğü üzere index'lerin sırası aynı olmasa bile pandas aynı index'deki değerler üzerinde aritmetiksel işlemleri yapmaktadır. Bazı index değerleri birbirinden farklı olan seriler üzerinde aritmetiksel işlemler yapılmak istenirse bir seride olup diğerinde olmayan indexler NaN (Not a Number) değeri almaktadır.

```
seri1=pd.Series([4,2,6,8,5],index=("elma","armut","üzüm","çilek","erik"))
seri2=pd.Series([5,6,1,3,7],index=("elma","armut","üzüm","çilek","kaysı"))
seri1+seri2
armut     8.0
elma      9.0
erik      NaN
kaysı     NaN
çilek    11.0
üzüm      7.0
dtype: float64
```

NaN değerinin olma sebebi, bir değerin bir seride olup diğerinde olmamasından dolayı, seri içerisinde olan bir veri ile olmayan bir veriyi toplanmayacağından dolayı oluşmaktadır. Aslında burada akla gelen ilk soru olan değerle olmayan değeri 0 kabul edilerek toplanabileceğidir. Ancak veri analizinde eksik bilgilerin üzerinde bizden habersiz işlem yapılması hatalı sonuçlar üreteceği için bu şekilde işlem yapılmadan çıktı vermesi çok önemlidir.

Serilerde Özel Metodlar

Pythonda alışık olduğumuz sum() max() min() gibi fonksiyonları kullanarak veriler üzerinde çeşitli işlemler yapabiliriz.

- Sum() metodu ile toplama işlemi

  Arraylerde kullandığımız gibi sum() metodu ile serinin değerlerini toplayabiliriz.

  ```
  seri=pd.Series([1,2,3,4,5,6,7,8])
  ```

seri1.sum()

```
25
```

- Max() metodu ile serideki en büyük değeri bulabiliriz.

seri.max()

```
8
```

- Min() metodu ile serideki en küçük değeri bulabiliriz.

seri.min()

```
1
```

- mean() metodu ile serideki değerlerin ortalamasını bulabiliriz.

seri.mean()

```
4.5
```

Read_csv() metodu ile cvs dosyalarını okumak

Seriler ve dataframelerle çalışırken cvs dosyaları sıkça kullanılır. CSV Virgülle ayrılmış değerler anlamına gelmektedir. Yani dosyanın içeriğinde aralarına virgül koyularak birbirinden ayrılmış metin veya rakamlar yer almaktadır. CSV uzantılı dosyalar not defteriyle de açılabilmesine rağmen onları doğru ve anlaşılır bir şekilde görüntülemek için Microsoft Excel veya Access gibi programlardan faydalanılmaktadır. Şimdi basit bir CSV dosyası oluşturalım. Bir not defteri dosyası açarak içerisine aşağıdaki değerleri alt alta yazalım, kaydetme işlemini yaparken farklı kaydet seçeneğini seçerek ismini şehirler.csv yaparak Kodlama türünü UTF-8 olarak bırakalım

Şehir
Ankara
İstanbul
İzmir
Antalya
Hatay
Adana
Trabzon
Balıkesir
Aydın

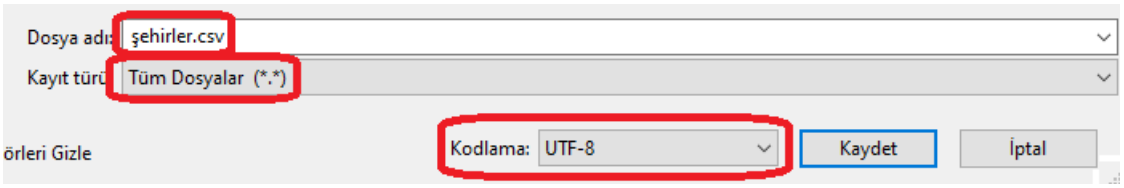

Burada ilk satırdaki değer olan “Şehir” değeri sütun ismi olacaktır. Biz burada tek sütun kullandığımız için pandas şehirlere sırasıyla indis değerleri atayacaktır. Eğer birden fazla sütun kullanırsak en soldaki sütun index değerleri olacaktır. Bunun haricinde eklediğimiz her virgülden sonraki değer yeni bir sütun olarak karşımıza çıkacaktır.

pd.read_csv("C:/Users/asus/Desktop/veriler/şehirler.csv")

	Şehir
0	Ankara
1	İstanbul
2	İzmir
3	Antalya
4	Hatay
5	Adana
6	Trabzon
7	Balıkesir
8	Aydın

Resim 72

Elinizde daha önceden oluşturulmuş dosyalar olduğunu varsayarsak bunların içerikleri ile ilgili işlemler yapılabilir. Bunun için masaüstünde veriler isimli klasör içerisinde şehir.csv isim dosyanın olduğunu varsayarak

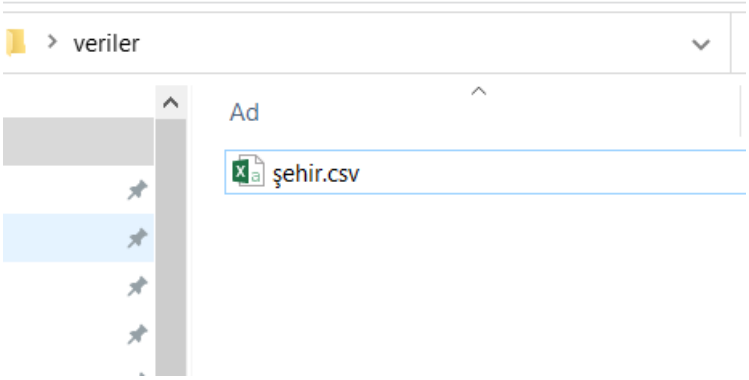

İlgili dosyaya erişmek için
pd.read_csv("C:/Users/asus/Desktop/veriler/şehir.csv")

	Şehir
0	Ankara
1	İstanbul
2	İzmir
3	Antalya
4	Hatay
5	Adana
6	Trabzon
7	Balıkesir
8	Aydın
9	Muğla
10	Kayseyi
11	Afyon

Şeklinde dosyaya erişim sağlayabiliriz. Read_csv metodunun parametrelerini öğrenmek için parantez içinde “shift+tab” tuş kombinasyonuna basabiliriz.

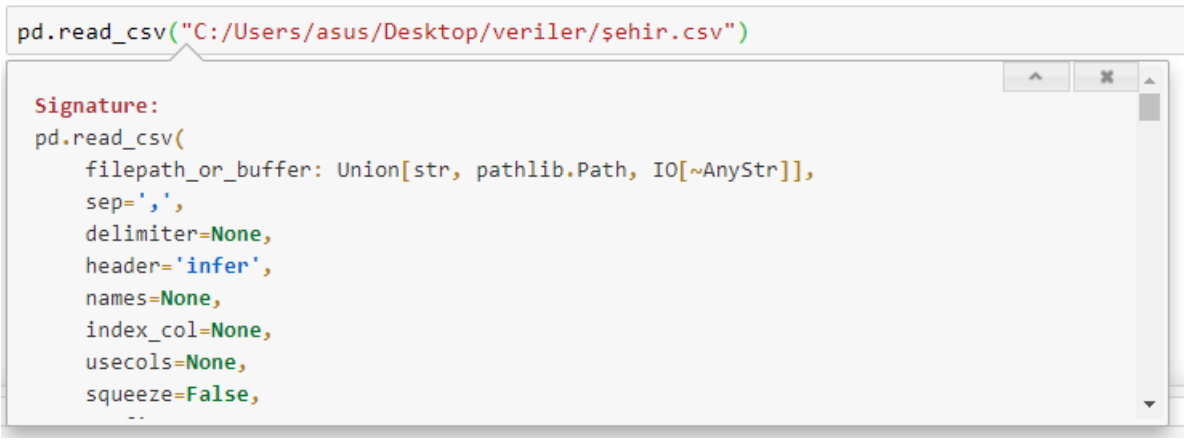

squeeze parametresine True değeri verilerek değerin indis numaraları görüntülenebilir.

pd.read_csv("C:/Users/asus/Desktop/veriler/şehir.csv",squeeze=True)

```
0        Ankara
1      İstanbul
2         İzmir
3       Antalya
4         Hatay
5         Adana
6       Trabzon
7     Balıkesir
8         Aydın
9         Muğla
10      Kayseyi
11        Afyon
Name: Şehir, dtype: object
```

Head() metodu kullanılarak üst kısımdan değerler görüntülenebilir. Eğer head() metoduna parametre girmezsek ilk 5 değeri görüntüler. Bunun için okuduğumuz dosyadan dönen değeri bir değişkene atayalım.

veri=pd.read_csv("C:/Users/asus/Desktop/veriler/şehir.csv",squeeze=True)

veri.head()

```
0      Ankara
1    İstanbul
2       İzmir
3     Antalya
4       Hatay
Name: Şehir, dtype: object
```

Head() metodunun içerisine parametre girerek daha fazla değer görüntüleyelim.

veri.head(8)

```
0      Ankara
1    İstanbul
2       İzmir
3     Antalya
4       Hatay
5       Adana
6     Trabzon
7   Balıkesir
Name: Şehir, dtype: object
```

Tail() metodu ile head() metodunun yaptığı işlemin tam tersini yaparak sondan görüntüleme işlemi yapar.

veri.tail()

```
7     Balıkesir
8         Aydın
9         Muğla
10      Kayseyi
11        Afyon
Name: Şehir, dtype: object
```

Size ve len fonksiyonları ile serinin eleman sayısını öğrenebiliriz.

len(veri)

```
12
```

veri.size

```
12
```

Sıralama işlemi yapmak için sorted() metodunu kulanabiliriz.

sorted(veri)

```
['Adana',
 'Afyon',
 'Ankara',
 'Antalya',
 'Aydın',
 'Balıkesir',
 'Hatay',
 'Kayseyi',
 'Muğla',
 'Trabzon',
 'İstanbul',
 'İzmir']
```

DataFrame ve Özellikleri

DataFrame'ler serilerin birleşmesinden oluşan yapılardır. Genellikle farklı tipteki sütun ve satırlara sahip SQL tablolarına benzetilir. DataFrame'ler veriyi daha kolay işlememizi sağlarlar. DataFrame'ler genellikle veri tabanlarındaki tablolara benzetilmektedir. Columns(Sütunlar) ve index'lerden(satırlar) oluşmaktadır. Bu değerler üzerinden veri analizi yapılabilmektedir.

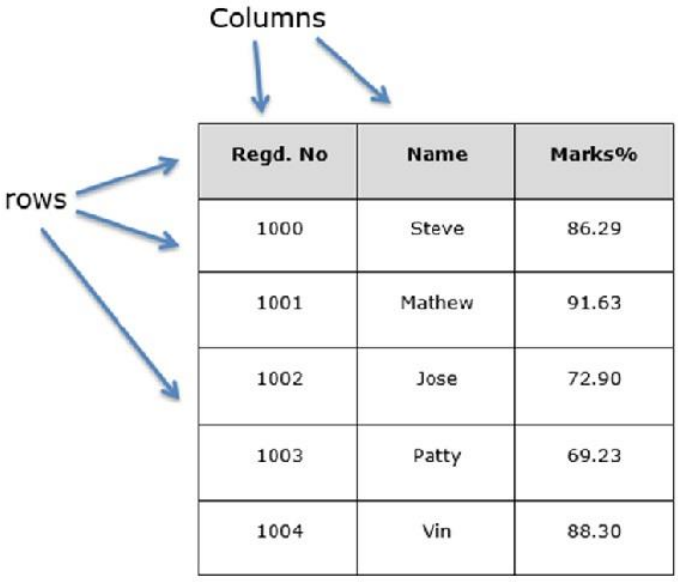

Bir DataFrame oluşturmak için,

pd.DataFrame([1,2,3,4,5])

	0
0	1
1	2
2	3
3	4
4	5

Resim7

şeklinde bir tanımlama yapabiliriz. Burada istersek sütunlarımızın ismini de değiştirebiliriz.

pd.DataFrame([1,2,3,4,5],columns=["sütun"])

	sütun
0	1
1	2
2	3
3	4
4	5

Resim 8

Görüldüğü üzere DataFrame'in sütun ismini değiştirmiş olduk. parantez içinde shift+tab tuş kombinasyonuna basarak DataFrame'in alabileceği parametreleri görebiliriz.

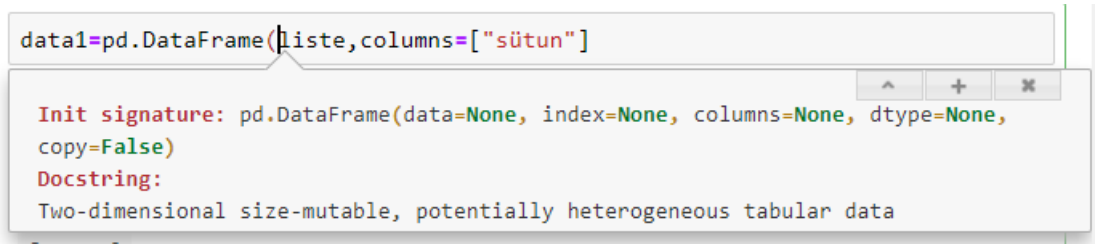

Resim 9

type() fonksiyonu ile DataFrame'in tipini incelersek,

data1=pd.DataFrame([1,2,3,4,5],columns=["sütun"])

type(data1)

pandas.core.frame.DataFrame

veri tipinin DataFrame olduğunu gördük.

axes metodu ile özelliklerini görüntülemek istersek,

data1.axes

[RangeIndex(start=0, stop=5, step=1), Index(['sütun'], dtype='object')]

İndex değeri 0'dan başlayıp 5'te bitmiş ve birer birer artmıştır. Sütun bazında ise sütun isminin "sütun " olduğu görülmektedir.

Satır isimlerini belirlemek için ise index metodu kullanılmalıdır.

pd.DataFrame([1,2,3,4,5],columns=["sütun"],index=["a","b","c","d","e"])

	sütun
a	1
b	2
c	3
d	4
e	5

Resim 42

Boyut sayısını öğrenmek için ndim metodu kullanabiliriz

data1.ndim

2

Boyut bilgisi için shape metodu kullanabiliriz.

data1.shape

```
(5, 1)
```

Eleman sayısını öğrenmek için size metodunu kullanabiliriz.(aynı işlemi len fonksiyonu ile de yapabiliriz)

data1.size

5

Listelerden DataFrame Oluşturmak

Elimizdeki bir listeyi kolaylıkla DataFrame'e dönüştürebiliriz.

liste=[2,4,6,8]

pd.DataFrame(liste,columns=["sütun1"])

	sütun1
0	2
1	4
2	6
3	8

Resim 10

Numpy Array'lerinden DataFrame Oluşturmak

Array'leri DataFrame'lere dönüştürmek için tıpkı listelerde yaptığımız gibi array'leri de DataFrame'lere dönüştürebiliriz.

a=np.array([1,3,5,7,9])

pd.DataFrame(a,columns=["sütun1"])

	sütun1
0	1
1	3
2	5
3	7
4	9

Resim 11

İki boyutlu array'i DataFrame'e dönüştürmek için 5 satır 3 sütunluk bir array oluşturalım

b=np.arange(1,16).reshape(5,3)

pd.DataFrame(b,columns=["sütun1","sütun2","sütun3"])

	sütun1	sütun2	sütun3
0	1	2	3
1	4	5	6
2	7	8	9
3	10	11	12
4	13	14	15

Resim 12

Burada array kaç sütunlu ise o kadar sütun ismi girilmesi gerekmektedir. aksi halde hata ile karşılaşırız.

Pandas Seri'lerinden DataFrame Oluşturma

Serilerden de DataFrame'ler oluşturabiliriz.

```
data1=pd.Series([1,2,3,4])
pd.DataFrame(data1,columns=["Sütun"])
```

	Sütun
0	1
1	2
2	3
3	4

Resim 13

Birden fazla seri ile DataFrame oluşturmak istenirse sözlük yapısına benzer bir yapı kullanılmalıdır.

```
data1=pd.Series([1,2,3,4])
data2=pd.Series([5,6,7,8])
pd.DataFrame({"sütun1":data1,"sütun2":data2})
```

	sütun1	sütun2
0	1	5
1	2	6
2	3	7
3	4	8

Resim 14

Sözlüklerden DataFrame Oluşturma

Önceki bölümde birden fazla seriden DataFrame oluştururken sözlük yapısına benzer bir yapı ile işlemimizi gerçekleştirmiştik, burada daha karışık bir yapı kullanarak DataFrame oluşturma işlemini gerçekleştirelim.

```
data={"sütun1":{"satır1":1,"satır2":4,"satır3":7},
    "sütun2":{"satır1":2,"satır2":5,"satır3":8},
     "sütun3":{"satır1":3,"satır2":6,"satır3":9}}
pd.DataFrame(data)
```

	sütun1	sütun2	sütun3
satır1	1	2	3
satır2	4	5	6
satır3	7	8	9

Resim 15

DataFrame'deki Sütunları Değişkene Atamak

DataFrame'lerdeki değerleri bir değişkene atayarak üzerinde işlemler yapabiliriz.

```
a=np.arange(1,16).reshape(5,3)
df=pd.DataFrame(a,columns=["sütun1","sütun2","sütun3"])
df
```

	sütun1	sütun2	sütun3
0	1	2	3
1	4	5	6
2	7	8	9
3	10	11	12
4	13	14	15

Resim 95

Sütun değerlerini değişkenlere atamak için

x=df["sütun1"]

x

```
0     1
1     4
2     7
3    10
4    13
Name: sütun1, dtype: int32
```

type(x)

```
pandas.core.series.Series
```

x değişkeni seri olmuştur.

eğer bir değişkene birden fazla sütun atarsak veri türü DataFrame olur.

x=df[["sütun1","sütun2"]]

x

	sütun1	sütun2
0	1	2
1	4	5
2	7	8
3	10	11
4	13	14

Resim 96

DataFrame'lerin satır ve sütun bilgilerine erişme

Elimizde bulunan DataFrame'e ait satır ve sütun bilgilerine ulaşabiliriz bunun için

data=pd.DataFrame([1,2,3,4],columns=["sütun1"],index=["s1","s2","s3","s4"])

elimizde yukarıdaki gibi bir veri seti olduğunu varsayalım. Satır bilgileri için

data.index

```
Index(['s1', 's2', 's3', 's4'], dtype='object')
```

Sütun bilgileri için

data.columns

```
Index(['sütun1'], dtype='object')
```

Şeklinde satır ve sütun bilgilerine erişebiliriz.

DataFrame'in Satır ve Sütun İsimlerini Yeniden Adlandırma

DataFrame'leri oluşturma işleminde satır ve sütun isimlerini belirlemek için

data=pd.DataFrame([1,2,3,4],columns=["sütun1"],index=["s1","s2","s3","s4"])

data

	sütun1
s1	1
s2	2
s3	3
s4	4

Şeklinde bir tanımlama yapmamız gerekmektedir. DataFrame oluşturduktan sonra satır ve sütun değerlerini değiştirebiliriz bunun için

data.columns=["veri"]

data

	veri
s1	1
s2	2
s3	3
s4	4

Resim 17

Satır isimlerini(index) değiştirmek için

data.index=["satı1","satır2","satır3","satır4"]

data

	veri
satı1	1
satır2	2
satır3	3
satır4	4

Resim 18

İşlemlerinin yapılması gerekmektedir.

DataFrame Eleman İşlemleri

Satırlara(Gözlemlere) Erişim İşlemleri

DataFrame'ler üzerinde indexleme işlemleri yapılabilmektedir. DataFrame'ler üzerinde bulunan satırlar gözlem olarak ifade edilmektedir.

a=np.random.randint(10,size=6)

b=np.random.randint(10,size=6)

c=np.random.randint(10,size=6)

data=pd.DataFrame({"s1":a,"s2":b,"s3":c})

data

	s1	s2	s3
0	3	9	4
1	3	2	3
2	6	3	0
3	1	7	0
4	8	2	1
5	5	1	0

Resim 19

Oluşturduğumuz DataFrame'de satır seçme işlemleri yapabilmek için,

data[0:1]

	s1	s2	s3
0	3	9	4

Resim 20

Yukarıdaki işlemle 1. Satırdaki verileri seçmiş olduk.

1,2 ve 3. Satırdaki değerlere ulaşmak için

data[1:4]

	s1	s2	s3
1	3	2	3
2	6	3	0
3	1	7	0

Resim 21

İşleminin yapılması gerekmektedir. Biz burada index isimlerini yazarak satırlardaki değerlere ulaşmak istersek hata ile karşılaşırız. Satırlara dilimleme işlemi yapmadan erişmek için loc ve iloc ifadelerinden faydalanmamız gerekmektedir. Eğer kendi verdiğimiz index isimleri ile ulaşmak istersek loc ifadesini orijinal indis değerleri ile ulaşmak istersek iloc ifadesini kullanmamız gerekmektedir. şimdi dataFrame'in index değerlerini değiştirelim.

data.index=(10,20,30,40,50,70)

data

	s1	s2	s3
10	4	7	4
20	6	7	1
30	3	1	1
40	0	8	0
50	0	9	2
70	2	7	7

Resim 44

Kendi verdiğimiz index değerlerine göre ulaşmak için

data.loc[20]

```
s1    6
s2    7
s3    1
Name: 20, dtype: int32
```

Varsayılan indis değerlerine göre erişebilmek için ise iloc ifadesini kullanmalıyız.

data.iloc[1]

```
s1    6
s2    7
s3    1
Name: 20, dtype: int32
```

Silme(drop) İşlemleri

Oluşturduğumuz DataFrame'in satır ve sütunlarında silme işlemleri yapabiliriz. Bunun için drop parametresinin kullanılması gerekmektedir.

data.drop("silinecek satır ya da sütun ismi", axis=(satır silinecekse 0 sütun silinecekse 1 değeri verilmedilir)) drop metodunun aldığı parametreleri görmek için parantez içerisinde shift+tab tuş kombinasyonuna basalım

```
data.drop()
```

```
Signature:
data.drop(
    labels=None,
    axis=0,
    index=None,
    columns=None,
    level=None,
    inplace=False,
    errors='raise',
)
```

Resim 43

Drop metodunun varsayılan parametrelerine bakıldığı zaman axis değerinin 0 olduğu görülmektedir. Sadece satır ismi yazılarak istenilen satır silinebileceği gibi axis değeri 0 verilerek de silme işlemi yapılabilir.

data.drop(2,axis=0)

	s1	s2	s3
0	3	9	4
1	3	2	3
3	1	7	0
4	8	2	1
5	5	1	0

Resim 22

Görüldüğü üzere 2 numaralı satırdaki değerler silinmiştir. Sütun silme işlemi için ise

data.drop("s2",axis=1)

	s1	s3
0	3	4
1	3	3
2	6	0
3	1	0
4	8	1
5	5	0

Resim 23

s2 isimli sütun silinmiştir. Burada axis değerinin doğru belirtilmesi çok önemlidir. axis değeri sütun silinmek istendiği zaman belirtilmez ya da satır silinirken 1 sütun silinirken 0 değeri verilmeye çalışılırsa hata ile karşılaşılır.

```
KeyError                                  Traceback (most recent call last)
<ipython-input-38-5d14ced7b27b> in <module>
----> 1 data.drop("s2",axis=0)

~\Anaconda3\lib\site-packages\pandas\core\frame.py in drop(self, labels, axis, index, columns, level, inplace, errors)
   4115             level=level,
   4116             inplace=inplace,
-> 4117             errors=errors,
   4118         )
   4119

~\Anaconda3\lib\site-packages\pandas\core\generic.py in drop(self, labels, axis, index, columns, level, inplace, errors)
   3912         for axis, labels in axes.items():
   3913             if labels is not None:
-> 3914                 obj = obj._drop_axis(labels, axis, level=level, errors=errors)
   3915
   3916         if inplace:

~\Anaconda3\lib\site-packages\pandas\core\generic.py in _drop_axis(self, labels, axis, level, errors)
   3944                 new_axis = axis.drop(labels, level=level, errors=errors)
   3945             else:
-> 3946                 new_axis = axis.drop(labels, errors=errors)
   3947             result = self.reindex(**{axis_name: new_axis})
   3948

~\Anaconda3\lib\site-packages\pandas\core\indexes\base.py in drop(self, labels, errors)
   5338         if mask.any():
   5339             if errors != "ignore":
-> 5340                 raise KeyError("{} not found in axis".format(labels[mask]))
   5341             indexer = indexer[~mask]
   5342         return self.delete(indexer)

KeyError: "['s2'] not found in axis"
```

Resim 24

Eğer aynı anda birden fazla satır veya sütun silmek istersek

a=[1,2,3]

data.drop(a,axis=0)

	s1	s2	s3
0	9	5	2
4	9	4	9
5	5	9	8

Resim 28

Aynı işlemi sütunlar üzerinde uygulamak istersek

a=["s2","s3"]

data.drop(a,axis=1)

	s1
0	9
1	9
2	0
3	3
4	9
5	5

Resim 29

Yapılan Değişikliklerin DataFrame'e Kaydedilmesi (inplace)

Bu zamana kadar yaptığımız işlemlerde fark edildiği üzere yapılan işlemler DataFrame üzerinde bir değişiklik yapmamıştır. Yani drop metodu ile değerler silinmiş olsa bile DataFrame tekrar görüntülendiğinde değişikliğin DataFrame üzerinde uygulanmadığı görülecektir. Yani silme işleminden sonra DaraFrame tekrar görüntülenmek istenirse

data

	s1	s2	s3
0	3	9	4
1	3	2	3
2	6	3	0
3	1	7	0
4	8	2	1
5	5	1	0

Silme işlemleri uygulanmamıştır. Bunun için inplace metodunun kullanılması gerekmektedir. Drop metodunun alacağı parametrelere bakmak için tuş kombinasyonuna baktığımızda

```
data.drop()
```

```
Signature:
data.drop(
    labels=None,
    axis=0,
    index=None,
    columns=None,
    level=None,
    inplace=False,
    errors='raise',
)
```

Resim 26

İnplace değerinin varsayılan olarak False olduğu görülür. Bu özelliğin False olması çok önemlidir. çünkü elimizde bulunan DataFrame'ler üzerinde yapılan değişiklikler büyük veri kayıplarına neden olacağı için bu işlem kalıcı değişikliklerin önüne geçmektedir.

data.drop("s2",axis=1,inplace=True)

data

	s1	s3
0	3	4
1	3	3
2	6	0
3	1	0
4	8	1
5	5	0

Resim 27

İnplace parametresine True değeri verdiğimiz için data isimli değişkende yapılan değişiklikler uygulanmış oldu.

DataFrame'lerde Sütunlara(Değişkenlere) Erişim İşlemleri

DataFrame'lerde sütun(değişken) ismi yazılarak değere ulaşılabilir.

```
data={"sütun1":{"satır1":1,"satır2":4,"satır3":7},
    "sütun2":{"satır1":2,"satır2":5,"satır3":8},
     "sütun3":{"satır1":3,"satır2":6,"satır3":9}}
df=pd.DataFrame(data)
df["sütun1"]
```

```
satır1    1
satır2    4
satır3    7
```

```
Name: sütun1, dtype: int64
```
Aynı işlemi tırnak işareti kullanmadan da yapabiliriz,

df.sütun1

```
satır1    1
satır2    4
satır3    7
Name: sütun1, dtype: int64
```
Çoklu seçim işlemleri için sütun isimleri iç içe parantez içerisinde yazılmalıdır.

df[["sütun1","sütun2"]]

	sütun1	sütun2
satır1	1	2
satır2	4	5
satır3	7	8

Resim 30

DataFrame'lere Sütun(Değişken) Ekleme İşlemi

DataFrame'lere sözlüklere eleman ekleme işlemi yaparken kullandığımız metodlardaki gibi eleman ekleyebiliriz.

df["sütun4"]=10,11,12

df

	sütun1	sütun2	sütun3	sütun4
satır1	1	2	3	10
satır2	4	5	6	11
satır3	7	8	9	12

Resim 31

Bu işlemi yaparken oluşturacağımız yeni sütunu(değişkeni) diğer sütunların toplamı, farkı, çarpımı gibi aritmetiksel işlemlerin sonucu şeklinde belirleyebiliriz.

df["sütun5"]=df["sütun1"] * df["sütun2"]

df

	sütun1	sütun2	sütun3	sütun4	sütun5
satır1	1	2	3	10	2
satır2	4	5	6	11	20
satır3	7	8	9	12	56

Resim 32

Satır ve Sütunlara Birlikte Erişme İşlemi

Biz daha önce satırlara erişim işlemlerini,

a=np.random.randint(10,size=6)

b=np.random.randint(10,size=6)

c=np.random.randint(10,size=6)

d=np.random.randint(10,size=6)

data=pd.DataFrame({"s1":a,"s2":b,"s3":c,"s4":d})

data[0:2]

	s1	s2	s3	s4
0	6	2	5	2
1	2	9	1	3

Resim 33

Ve sütunlara erişim işlemlerini görmüştük,

data[["s1","s2"]]

	s1	s2
0	1	3
1	9	3
2	5	7
3	2	9
4	0	8
5	7	0

Resim 34

Satır ve sütunlara beraber erişmek için iloc metodu kullanılmalıdır.

data.iloc[1:3,0:3]

	s1	s2	s3
1	2	9	1
2	1	4	5

Hatırlanacağı üzere iloc metodu bizim verdiğimiz satır ve sütun isimlerini göz ardı ederek indis değerleri üzerinden listeleme işlemleri yapıyordu. Köşeli parantez içerisinde verilen birinci parametre dilimleme yapılacak satırları virgül işaretinden sonraki ikinci parametre ise dilimleme işlemi yapılacak sütunları ifade eder.

Eğer loc ifadesi kullanılarak satır ve sütunlara birlikte erişilmek istenirse satır ve sütunlara verilen isimlere sadık kalarak yazılması gerekmektedir.

data.loc[1:3,"s1":"s3"]

	s1	s2	s3
1	2	9	1
2	1	4	5
3	8	4	4

Resim 37

Hatırlanacağı üzere loc ifadesi kullanıldığı zaman yazılan başlangıç değeri ile birlikte bitiş değerini de dahil ediyordu.

Satır ve sütunlara birlikte erişilmek istendiği zaman iloc ve loc ifadesi kullanılmadan erişilmek istenirse hata ile karşılaşılır.

data[1:3,0:3]

```
TypeError                                 Traceback (most recent call last)
<ipython-input-55-86f3f155ddab> in <module>
----> 1 data[1:3,0:3]

~\Anaconda3\lib\site-packages\pandas\core\frame.py in __getitem__(self, key)
   2993             if self.columns.nlevels > 1:
   2994                 return self._getitem_multilevel(key)
-> 2995             indexer = self.columns.get_loc(key)
   2996             if is_integer(indexer):
   2997                 indexer = [indexer]

~\Anaconda3\lib\site-packages\pandas\core\indexes\base.py in get_loc(self, key, method, tolerance)
   2895                 )
   2896             try:
-> 2897                 return self._engine.get_loc(key)
   2898             except KeyError:
   2899                 return self._engine.get_loc(self._maybe_cast_indexer(key))

pandas/_libs/index.pyx in pandas._libs.index.IndexEngine.get_loc()

pandas/_libs/index.pyx in pandas._libs.index.IndexEngine.get_loc()

TypeError: '(slice(1, 3, None), slice(0, 3, None))' is an invalid key
```

Resim 38

Ya da dilimleme işlemleri yapmadan erişmek istersek

data.loc[2,"s2"]

1

İşlemiyle satır ve sütunların kesişim yerlerine loc ifadesiyle erişebiliriz.

DataFrame'lerde Koşullu İşlemler

DataFrame'ler üzerinde serilerde yaptığımız gibi koşullu işlemler uygulayabiliriz. Örnek olarak DataFrame içerisinde 5'ten büyük değerler için bir koşullu ifade belirtelim

data>5

	s1	s2	s3	s4
0	True	False	False	False
1	False	True	False	False
2	False	False	False	True
3	True	False	False	False
4	False	True	False	False
5	True	False	True	False

Resim 39

Tıpkı serilerdeki gibi

data[data>5]

	s1	s2	s3	s4
0	6.0	NaN	NaN	NaN
1	NaN	9.0	NaN	NaN
2	NaN	NaN	NaN	8.0
3	8.0	NaN	NaN	NaN
4	NaN	8.0	NaN	NaN
5	8.0	NaN	6.0	NaN

Resim 40

Şeklinde bir işlem yapmak istersek 5'den büyük değerler görüntülenir ancak 5 ve küçük değerler NotaNumber(NaN) hatası vermektedir. Eğer seçim işlemlerinde kısıtlamaya gitmek istersek

data[data.s2>5]

	s1	s2	s3	s4
1	2	9	1	3
4	1	8	0	0

Resim 41

Aynı işlemi

data[data["s2"]>5]

şeklinde de yapabiliriz

Koşul ifadesini s2 sütununda 5'den büyük değerler için belirledik, ancak DataFrame'de listeleme yaparken koşulu sağlayan tüm değerler listelemeye dahil edildiği için satır ve sütun değerleri görüntülenmiş oldu. Buna göre bir koşul daha yazarak yani sütun ismi yazarak arama işlemini daraltabiliriz.

data[data.s2>5]["s2"]

```
1    9
4    8
Name: s2, dtype: int32
```

Eksik Verilerin Tamamlanması

Veri analizi yaparken elimize gelen veriler eksik olabilir. Bu konuyu sonraki bölümlerde detaylı inceleyeceğiz. Ancak öğrendiğimiz bilgiler eşliğinde eksik bilgileri tamamlama işlemi yapmayı deneyelim. Şimdi içerisinde eksik veriler olan 3 satır 3 sütunluk bir array oluşturalım

a=np.array([[7,np.nan,12],[np.nan,np.nan,5],[np.nan,15,9]])

data=pd.DataFrame(a,index=["satır1","satır2","satır3"],columns=["sütun","sütun2","sütun3"])

data

	sütun	sütun2	sütun3
satır1	7.0	NaN	12.0
satır2	NaN	NaN	5.0
satır3	NaN	15.0	9.0

Resim 45

DataFrame'de işlem yapabilmek için nan olan değerlerin yerine belirlediğimiz değerleri vermemiz gerekebilir. Bu değerleri fillna metodu ile istediğimiz gibi değiştirebiliriz.

data.fillna(value=0)

	sütun	sütun2	sütun3
satır1	7.0	0.0	12.0
satır2	0.0	0.0	5.0
satır3	0.0	15.0	9.0

Resim 46

Eğer nan değerlerinin yerine DataFramedeki diğer değerlerin ortalamasını bulmak yerleştirmek istersek. DataFrame'de bulunan her satırdaki değeri toplamak için sum() fonksiyonu kullanılmalıdır

data.sum()

```
sütun      7.0
sütun2    15.0
sütun3    26.0
dtype: float64
```

eğer

data.sum().sum()

```
48.0
```

Şeklinde bir tanımlama yaparsak tüm değerlerin toplamını bulma işlemi yaparız. Şimdi DataFrame'deki eleman sayısını bulalım,

data.size

9

Ancak buradaki değerlerin bazıları nan olduğu için değerlendirmeye katılmaması gerekmektedir. bunun için

data.isnull().sum().sum()

4

Şeklinde bir parametre kullanmamız gerekmektedir.

Şimdi ortalamayı bulmak için DataFrame'deki değerlerin toplamını eleman sayısına bölelim

ort=(data.sum().sum())/(data.size- data.isnull().sum().sum())

ort

9.6

Artık bulduğumuz ortalama değerini eksik verilerin yerine koyabiliriz.

data.fillna(value=ort)

	sütun	sütun2	sütun3
satır1	7.0	9.6	12.0
satır2	9.6	9.6	5.0
satır3	9.6	15.0	9.0

Resim 47

DataFrame'leri Birleştirme İşlemleri:

Hatırlanacağı üzere serileri birleştirmek için concat metodu kullanmıştık. DataFrame'leri birleştirmek için de concat metodu kullanabiliriz. Üç adet DataFrame oluşturalım.

a=np.random.randint(10,size=5)

b=np.random.randint(10,size=5)

c=np.random.randint(10,size=5)

data1=pd.DataFrame({"sütun1":a,"sütun2":b,"sütun3":c})

data1

	sütun1	sütun2	sütun3
0	7	6	1
1	1	6	1
2	5	7	5
3	1	9	2
4	2	6	8

Resim 73

Data1 isimli DataFrame'den yararlanarak ikinci DataFrame'i oluşturalım.

data2=data1+10

data2

	sütun1	sütun2	sütun3
0	17	16	11
1	11	16	11
2	15	17	15
3	11	19	12
4	12	16	18

Resim 74

2. DataFrame 1. nin 10 fazlası oldu.

Şimdi concat metodu ile iki DataFrame'i birleştirelim, varsayılan değer axis 0 olduğu için DataFrame'leri alt alta birleştirecektir.

pd.concat([data1,data2])

	sütun1	sütun2	sütun3
0	9	1	8
1	0	4	9
2	3	2	4
3	9	5	0
4	8	6	4
0	19	11	18
1	10	14	19
2	13	12	14
3	19	15	10
4	18	16	14

Resim 48

DataFrame'lerin her ikisinin de sütun isimleri aynı olduğu için alt alta toplama işlemi sorunsuz bir şekilde gerçekleşmiştir.

Eğer axis değerini 1 olarak belirtirsek birleştirme işlemi sütun bazında olacaktır. Her iki DataFrame'in index değerleri birbirine eşit olduğu için birleştirme işlemi sorunsuz bir şekilde gerçekleşecektir.

pd.concat([data1,data2],axis=1)

	sütun1	sütun2	sütun3	sütun1	sütun2	sütun3
0	9	1	8	19	11	18
1	0	4	9	10	14	19
2	3	2	4	13	12	14
3	9	5	0	19	15	10
4	8	6	4	18	16	14

Resim 49

Her iki birleştirme işleminde de index ve sütun isimlerine baktığımızda birbirlerini tekrarladığını görüyoruz. Yani birleştirme işleminden sonra index veya sütun değerleri 4 den sonra 5 ile devam etmeyip tekrar 0'a dönmüştür. Bu durumun önüne geçmek için birleştirme işleminde **ignore_index** metodu kullanılmalıdır. Concat metodunun aldığı parametrelere bakarsak **ignore_index** parametresinin aldığı değerin False olduğunu görürüz.

```
pd.concat([data1,data2],axis=1)
```

```
pd.concat(
    objs,
    axis=0,
    join='outer',
    join_axes=None,
    ignore_index=False,
    keys=None,
    levels=None,
    names=None,
    verify_integrity=False,
    sort=None,
```

Resim 50

Eğer bu parametreye True değeri verirsek

pd.concat([data1,data2],axis=0,ignore_index=True)

	sütun1	sütun2	sütun3
0	9	1	8
1	0	4	9
2	3	2	4
3	9	5	0
4	8	6	4
5	19	11	18
6	10	14	19
7	13	12	14
8	19	15	10
9	18	16	14

Resim 51

Burada index ve sütun isimleri aynı olduğunda sorunsuz bir şekilde birleştirme işlemini yapabildik. Eğer değişken isimlerinden bir ya da bir kaçı farklı olsaydı hata ile karşılaşacaktık

DataFrame'lerden birinin sütun isminin değişik olduğunu varsayarak tekrar işlem yapalım.

data2.columns=["sütun1","sütun2","veri"]

pd.concat([data1,data2],axis=0)

```
C:\Users\asus\Anaconda3\lib\site-packages\ipykernel_launcher.py:1: FutureWarning: Sorting because non-concatenation axis is not
aligned. A future version
of pandas will change to not sort by default.

To accept the future behavior, pass 'sort=False'.

To retain the current behavior and silence the warning, pass 'sort=True'.

  """Entry point for launching an IPython kernel.
```

	sütun1	sütun2	sütun3	veri
0	9	1	8.0	NaN
1	0	4	9.0	NaN
2	3	2	4.0	NaN
3	9	5	0.0	NaN
4	8	6	4.0	NaN
0	19	11	NaN	18.0
1	10	14	NaN	19.0
2	13	12	NaN	14.0
3	19	15	NaN	10.0
4	18	16	NaN	14.0

Resim 52

Sütun isimlerinin tamamı aynı olmadığı için ismi farklı olan sütun(veri) ayrı bir sütun olarak değerlendirilmiş ve DataFrame'in sonuna eklenmiştir. Ayrıca ilk değerler NaN olarak tanımlanmıştır.

Join metodu her iki DataFrame'de aynı isimde olan sütunları birleştirip farklı isimde olanları dikkate almaz.

data2.columns=["sütun1","sütun2","veri"]

pd.concat([data1,data2], join="inner")

	sütun1	sütun2
0	9	1
1	0	4
2	3	2
3	9	5
4	8	6
0	19	11
1	10	14
2	13	12
3	19	15
4	18	16

Resim 53

Join Metodu ile Birleştirme İşlemi

Join metodu DataFrame işlemlerinde concat metodundan ayrı olarak sıkça kullanılan metodlardan birisidir. Sql sorgularında kullanılan left join benzeri bir birleştirme işlemi yapar. Join metodu ile **index** değerlerine göre birleştirme işlemi yapabiliriz.

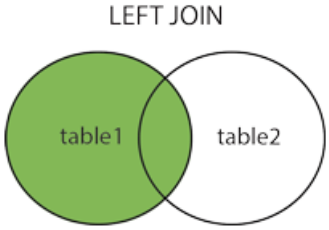

Resim 55

```
data1={"A":["A1","A2","A3","A4"],
    "B":["B1","B2","B3","B4"]}
df1=pd.DataFrame(data1)
df1
```

	A	B
0	A1	B1
1	A2	B2
2	A3	B3
3	A4	B4

Resim 75

```
data2={"C":["C1","C2","C3"],
    "D":["D1","D2","D3"]}
df2=pd.DataFrame(data2)
df2
```

	C	D
0	C1	D1
1	C2	D2
2	C3	D3

Resim 76

Burada birleştirme işleminde sol taraftaki table DataFrame1'i sağ taraftakini ise DataFrame2 olarak düşünürsek, table1'deki tüm index'ler ile yeni bir DataFrame oluşmuş olacaktır. Burada data1 4 adet index değerine data2 ise 3 adet index değerine sahiptir. Join işlemi uygularsak yukarıdaki şekilde incelediğimiz gibi sol taraftaki DataFrame'in yapısına uygun bir şekilde birleştirme işlemi yapılacaktır.

df1.join(df2)

	A	B	C	D
0	A1	B1	C1	D1
1	A2	B2	C2	D2
2	A3	B3	C3	D3
3	A4	B4	NaN	NaN

Resim 56

Aynı işlemi tersten yapmış olsaydık, yani data2 isimli DataFrame'i sola almış olsaydık birleştirme işlemini yaparken data1'i data2 ye uyarlayacağı için en alttaki indis değerleri silinecekti

df2.join(df1)

	C	D	A	B
0	C1	D1	A1	B1
1	C2	D2	A2	B2
2	C3	D3	A3	B3

Resim 57

Merge Metodu ile Birleştirme İşlemi

Merge metodu ile birleştirme işlemi SQL tablolardaki INNER JOIN işlemine benzemektedir. Her iki DataFrame'deki sütunlardan ortak olanına göre birleştirme işlemi yapılmaktadır. Elimizde ortak değişkenli iki adet DataFrame olduğunu varsayalım,

```
data1=pd.DataFrame({"A":["A1","A2","A3","A4"],
          "B":["B1","B2","B3","B4"],
            "ortak":["K1","K2","K3","K4"]})
data2=pd.DataFrame({"C":["C1","C2","C3"],
          "D":["D1","D2","D3"],
            "ortak":["K3","K4","K5"]})
```

data1

	A	B	ortak
0	A1	B1	K1
1	A2	B2	K2
2	A3	B3	K3
3	A4	B4	K4

Resim 58

data2

	C	D	ortak
0	C1	D1	K4
1	C2	D2	K5
2	C3	D3	K6

Resim 59

Burada ortak isimli sütuna göre birleştirme işlemi yapılacağına göre her iki DataFrame'de ortak isimli sütunda K4 değeri iki DataFrame'de de mevcut olduğundan

pd.merge(data1,data2)

	A	B	ortak	C	D
0	A3	B3	K3	C1	D1
1	A4	B4	K4	C2	D2

Resim 60

Şeklinde bir birleştirme işlemi yapılacaktır. Burada birleştirme işlemini daha detaylı inceleyecek olursak,

	A	B	ortak
0	A1	B1	K1
1	A2	B2	K2
2	A3	B3	K3
3	A4	B4	K4

	C	D	ortak
0	C1	D1	K3
1	C2	D2	K4
2	C3	D3	K5

	A	B	ortak	C	D
0	A3	B3	K3	C1	D1
1	A4	B4	K4	C2	D2

Resim 61

Ortak olan sütunlardaki ortak olan değerlere göre birleştirme işlemi yapılmıştır. Aynı işlemi tam tersi olarak yapmak istersek, yine aynı değerlere ulaşacaktık, çünkü ortak olan değerler değişmeyecektir. Join işlemi indexler üzerinden merge işlemi column'lar üzerinden birleştirme işlemi yapmaktadır.

DataFrame Üzerinde Uygulanabilen Metodlar

Veri analizinde sum , mean, median, min ve max fonkdiyonları ile özetleme yapabiliriz. Bu sayede veri hakkında genel bir kanıya ulaşılabilir.

count → Tüm elemanların sayısı

mean → Tüm elemanların ortalamalarını hesaplar

median → Tüm elemanların median'ı alır(ortadaki değer)

sum → Tüm elemanların toplamlarını alır

min, max → Tüm elemanların minimum ve maximum değerlerini getirir

std, var → Tüm elemanların standart sapmasını ve varyansını hesapları

prod → Tüm elamanların çarpımını hesaplar

Elimizde türliye'nin 1990 yılından bu yana ithalat ihracat rakamlarını içeren bir tablo olduğunu varsayalım

ithalatihracat.csv - Not Defteri

Dosya Düzen Biçim Görünüm Yardım

```
Yıllar,İhracat(X),İthalat(M),Fark(X-M)
1990,12.960,22.302,-1.400
1991,13.593,21.047,-7.453
1992,14.714,22.871,-8.156
1993,15.345,29.428,-14.083
1994,18.105,23.270,-5.164
1995,21.637,35.709,-14.071
1996,23.224,43.626,-20.402
1997,26.261,48.558,-22.297
1998,26.973,45.921,-18.947
1999,26.587,40.671,-14.084
2000,27.774,54.502,-26.727
2001,31.334,41.399,-10.064
2002,36.059,51.553,-15.494
```

Resim 62

Dosyayı read_csv metodu ile açarsak head metodu ile parametre girmeden ilk 5 veriye bakabiliriz. Head metodunun içerisine parametre vererek istediğimiz kadar değere bakabiliriz.

data=pd.read_csv("C:/Users/asus/Desktop/veriler/ithalatihracat.csv")

data.head()

	Yıllar	İhracat(X)	İthalat(M)	Fark(X-M)
0	1990	12.960	22.302	-1.400
1	1991	13.593	21.047	-7.453
2	1992	14.714	22.871	-8.156
3	1993	15.345	29.428	-14.083
4	1994	18.105	23.270	-5.164

Resim 63

Shape metodu ile index ve column sayılarına bakabiliriz.

data.shape

```
(28, 4)
```

28 satır ve 4 sütundan oluştuğu görülmektedir.

Count metodu ile her bir sütundaki gözlem sayılarına ulaşabiliriz.

data.count()

```
Yıllar        28
İhracat(X)    28
İthalat(M)    28
Fark(X-M)     28
dtype: int64
```

sadece bir sütuna ait gözlemlerin sayısına bakmak istersek

data["İhracat(X)"].count()

```
28
```

Şeklinde bir metod kullanabiliriz.

Sum() fonksiyonu ile her sütun değeri için toplamları bulabiliriz.

data.sum()

```
Yıllar        56098.000
İhracat(X)     2059.456
İthalat(M)     3213.457
Fark(X-M)     -1146.040
dtype: float64
```

mean() fonksiyonu ile ortalamalarını bulabiliriz.

data.mean()

```
Yıllar        2003.500000
İhracat(X)      73.552000
İthalat(M)     114.766321
Fark(X-M)      -40.930000
dtype: float64
```

describe fonksiyonu ile her bir sütun için eleman sayıları **max min** ortalamaları %25-%75 lik değerlerine ulaşılabilir

data.describe()

	Yıllar	İhracat(X)	İthalat(M)	Fark(X-M)
count	28.000000	28.000000	28.000000	28.000000
mean	2003.500000	73.552000	114.766321	-40.930000
std	8.225975	55.142128	85.016372	31.377309
min	1990.000000	12.960000	21.047000	-105.934000
25%	1996.750000	25.501750	41.217000	-65.030250
50%	2003.500000	55.209500	83.439000	-30.549500
75%	2010.250000	132.746750	199.454250	-14.083750
max	2017.000000	157.610000	251.661000	-1.400000

Resim 64

Group By İşlemleri

Groupby işlemi aynı gözlem adına sahip verileri kendi arasında işlem yapmamızı sağlar. Örnek olarak elimizde futbol takımlarının isimleri ve maaşların olduğu bir DataFrame olduğunu varsayalım.

```
data=pd.DataFrame({"takım":["galatasaray","fenerbahçe","fenerbahçe","galatasaray","beşiktaş"],
                   "maaş":[5000,3000,8000,4000,7000]})
```

data

	takım	maaş
0	galatasaray	5000
1	fenerbahçe	3000
2	fenerbahçe	8000
3	galatasaray	6000
4	beşiktaş	7000

Resim 65

Group By işlemleri sql sorgularında kullanılan Group By işlemlerine benzer. Şimdi galatasaray'da oynayan oyuncuların maaşlarını takım isimlerine göre groupby işlemi yapmak istersek

```
grup=data.groupby("takım")
```

grup

```
<pandas.core.groupby.generic.DataFrameGroupBy object at 0x000002BE99B37A88>
```

Şimdi grup değişkeninin üzerinde metodları uygulamak istersek

grup.sum()

takım	maaş
beşiktaş	7000
fenerbahçe	11000
galatasaray	9000

Resim 66

Grupların toplam değerleri bulundu.

Ortalamalarını bulmak istersek

grup.mean()

takım	maaş
beşiktaş	7000
fenerbahçe	5500
galatasaray	5500

Resim 67

Yapılan işlemi daraltmak istersek

data.groupby("takım").sum().loc["galatasaray"]

```
maaş     9000
Name: galatasaray, dtype: int64
```

Şeklinde bir kullanım yapabiliriz.

Count metodu ile her bir gruptaki değerlerin sayısına ulaşılabilir.

grup.count()

takım	maaş
beşiktaş	1
fenerbahçe	2
galatasaray	2

Resim 68

Her takımda alınan en düşük maaşlar

data.groupby("takım").min()

takım	maaş
beşiktaş	7000
fenerbahçe	3000
galatasaray	4000

Resim 77

data.groupby("takım").min()["maaş"]["galatasaray"]

```
4000
```

Galatasaray takımında alınan en düşük maaşı bulmuş olduk.

Her takımda alınan maaşların ortalamasını bulmak için

data.groupby("takım").mean()

takım	maaş
beşiktaş	7000
fenerbahçe	5500
galatasaray	4500

Resim 78

Özel Fonksiyonlar

DataFrame'lerde kullanabileceğimiz bazı özel fonksiyonlar bulunmaktadır.

```
df=pd.DataFrame({
   "sütun1":[1,2,3,4,5,6],
   "sütun2":[10,20,30,10,20,10],
   "sütun3":["ali","veli","ayşe","fatma","emre","büşra"]})
df
```

	sütun1	sütun2
0	ali	10
1	veli	20
2	ayşe	30
3	fatma	10
4	emre	20
5	büşra	10

Resim 79

DataFrame'in ilk değerlerini görmek için head fonksiyonu kullanıyorduk

df.head()

	sütun1	sütun2
0	ali	10
1	veli	20
2	ayşe	30
3	fatma	10
4	emre	20

Resim 80

DataFramedeki bazı değerlerin birden fazla kullanıldığı görülmektedir. Buradaki eşsiz değerleri görüntülemek için unique() fonksiyonu kullanılmalıdır.

df["sütun2"].unique()

```
array([10, 20, 30], dtype=int64)
```

Eşsiz değerlerin sayısını bulmak için nunique() fonksiyonu kullanılmalıdır.

df["sütun2"].nunique()

```
3
```

Her bir değerin kaç defa geçtiğini bulabilmek için value_counts() methodu kullanılmalıdır.

df["sütun2"].value_counts()

```
10    3
20    2
30    1
Name: sütun2, dtype: int64
```

Pivot Tablolar

Pivot Table(Özet Tablo) elimizdeki verilerin daha anlaşılır bir şekilde ve özet halinde sunulmasını sağlayan bir yöntemdir. MS-Excel ve MS-Acces programlarında sıklıkla kullanılır. Şimdi bir örnek üzerinden anlatmaya çalışalım.

```
data=pd.DataFrame({"Aylar":["Haziran","Temmuz","Ağustos","Haziran","Temmuz","Ağustos","Haziran","Temmuz","Ağustos"],
                   "Sıcaklık":[30,34,35,28,32,34,29,35,36],
                   "Şehirler":["İstanbul","İstanbul","İstanbul","Ankara","Ankara","Ankara","Antalya","Antalya","Antalya"]})
data
```

elimizde yukarıdaki gibi veri seti olduğunu varsayalım. Veri setinde 3 farklı şehre ait yaz mevsimi sıcaklık değerleri bulunmaktadır. Verileri görüntülediğimizde aşağıdaki gibi bir çıktı elde edebiliriz.

	Aylar	Sıcaklık	Şehirler
0	haziran	30	İstanbul
1	temmuz	34	İstanbul
2	ağustos	35	İstanbul
3	haziran	28	Ankara
4	temmuz	32	Ankara
5	ağustos	34	Ankara
6	haziran	29	Antalya
7	temmuz	35	Antalya
8	ağustos	36	Antalya

Resim 86

Data Frame'i pivot tablo ile tekrar düzenlemek istersek aşağıdaki kodları yazmamız gerekmektedir. pivot tablo hazırlarken ayları index değerler, şehirleri ise sütun değerleri olarak belirleyelim.

data.pivot_table(index="Aylar",columns="Şehirler",values="Sıcaklık")

Şehirler	Ankara	Antalya	İstanbul
Aylar			
ağustos	34	36	35
haziran	28	29	30
temmuz	32	35	34

Resim 87

Aggregate Fonksiyonu:

Aggregate fonksiyonu ile python'da işlevsel bir şekilde toplulaştırma işlemleri yapabiliriz. Elimizde takımların

```
import pandas as pd
import numpy as np
data=pd.DataFrame({"takımlar":["gs","fb","bjk","gs","fb","bjk"],
                   "attığıgoller":[188,192,176,194,190,189],
                   "yediğigoller":[70,76,68,82,70,60]})
```

Data

	takımlar	attığıgollder	yediğigoller
0	gs	188	70
1	fb	192	76
2	bjk	176	68
3	gs	194	82
4	fb	190	70
5	bjk	189	60

Resim 90

Şimdi dataframedeki gözlemlere göre(takım isimleri) tablomuzu daha sade hale getirelim.

data.groupby("takımlar").aggregate(["min",np.median,max])

	sezonlukgolsayıları			yediğigoller		
	min	median	max	min	median	max
takımlar						
bjk	176	182.5	189	60	64	68
fb	190	191.0	192	70	73	76
gs	188	191.0	194	70	76	82

Resim 91

Hatta tabloyu biraz daha sadeleştirerek takımların attığı en fazla gol sayıları ile yediği en az gol sayılarını listelemek istersek

data.groupby("takımlar").aggregate({"sezonlukgolsayıları":"max","yediğigoller":"min"})

	sezonlukgolsayıları	yediğigoller
takımlar		
bjk	189	60
fb	192	70
gs	194	70

Resim 92

Filter Fonksiyonu:

Filter fonksiyonu ile belirli kriterler belirleyerek bu kriterlere göre görüntüleme işlemleri yapabiliriz. Örnek olarak 190 dan fazla gol atan takımlara ulaşmak istediğimizde aşağıdaki gibi fonksiyon yazalım.

```
def filtre(a):
  return a["attığıgoller"].max()>190
```

şimdi fonksiyonumuzu çağıralım.

data.groupby("takımlar").filter(filtre)

	takımlar	attığıgoller	yediğigoller
0	gs	188	70
1	fb	192	76
3	gs	194	82
4	fb	190	70

Resim 93

Burada dikkat ettiyseniz gs nin ilk değer 188 olduğu halde, farklı bir gözlemde 190 değerini geçtiği için her iki gözlem değeri de görüntülenmiştir.

Apply Fonksiyonu:

Apply fonksiyonu satır ve sütunlar üzerinde hesaplama işlemleri yapmamızı sağlar.

data.groupby("takımlar").apply(np.sum)

	takımlar	attığıgoller	yediğigoller
takımlar			
bjk	bjkbjk	365	128
fb	fbfb	382	146
gs	gsgs	382	152

Resim 94

Görüldüğü üzere satırlar üzerinde toplama işlemi yapılmış oldu.

Veri Okuma Kaynakları

Önceki bölümde CSV uzantılı dosyaları okuma işlemi yapmıştık. Şimdi ise farklı dosyalar üzerinde(txt,xls) veri seti okuma işlemlerine değinelim.

Veri Analizi 1

Şimdi öğrendiğimiz bilgiler doğrultusunda bir veri analizi işlemi gerçekleştirelim.
Elimizde https://www.kaggle.com/ adresinden alınmış World Happiness Report isimli dataset'in 2019 verileri olsun dataset'i indirerek 2019 verisini açalım bunun için yukarıdaki adrese girerek datasets içerisinde pokemon araması yaptıralım ya da
https://www.kaggle.com/abcsds/pokemon
adresine giderek

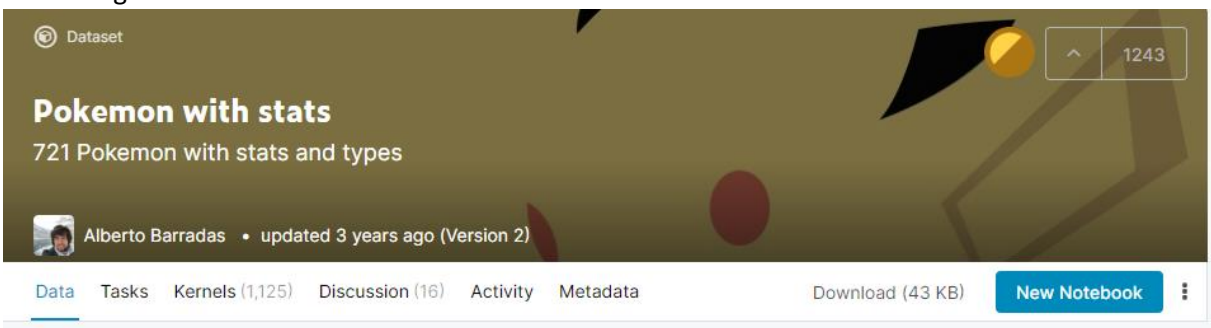

Resim 85

Dataset dosyasını indirelim. Daha sonra jupyter üzerinde dosyayı açalım.

data=pd.read_csv("C:/Users/asus/Desktop/veriler/pokemon.csv")
data .head()

	#	Name	Type 1	Type 2	Total	HP	Attack	Defense	Sp. Atk	Sp. Def	Speed	Generation	Legendary
0	1	Bulbasaur	Grass	Poison	318	45	49	49	65	65	45	1	False
1	2	Ivysaur	Grass	Poison	405	60	62	63	80	80	60	1	False
2	3	Venusaur	Grass	Poison	525	80	82	83	100	100	80	1	False
3	3	VenusaurMega Venusaur	Grass	Poison	625	80	100	123	122	120	80	1	False
4	4	Charmander	Fire	NaN	309	39	52	43	60	50	65	1	False

Resim 81

Burada pokemon'ların isimleri tipleri ile vuruş güçleri savunmaları gibi bilgiler bulunmaktadır.
Buradaki veri sayısını öğrenebilmek için,

data.index

```
RangeIndex(start=0, stop=800, step=1)
```

Ya da
len(data)

```
800
```

800 adet değer olduğu görülmektedir.
Yaşam güçlerinin(HP) ortalamasını bulabilmek için

data["HP"].mean()

```
69.25875
```

En yüksek yaşam gücünü bulmak için

data["HP"].max()

```
255
```

En yüksek attack gücüne sahip karakterin ismini bulalım, bunun için en yüksek attack gücüne sahip değeri bulalım,

data["Attack"].max()

```
190
```

Şimdi filtreleme işlemi yapalım

data[data["Attack"]==190]

	#	Name	Type 1	Type 2	Total	HP	Attack	Defense	Sp. Atk	Sp. Def	Speed	Generation	Legendary
163	150	MewtwoMega Mewtwo X	Psychic	Fighting	780	106	190	100	154	100	130	1	True

Resim 82

Bu karakterin type1 ini almak istersek

data[data["Attack"]==190]["Type 1"].iloc[0]

```
'Psychic'
```

Pikachu karakterinin Defence'ini bulalım

data[data["Name"]=="Pikachu"]["Defense"].iloc[0]

```
40
```

Type1'e göre gruplara ayırarak her bir grubun ortalama güçlerini bulalım.

data.groupby("Type 1").mean()

Type 1	#	Total	HP	Attack	Defense	Sp. Atk	Sp. Def	Speed	Generation	Legendary
Bug	334.492754	378.927536	56.884058	70.971014	70.724638	53.869565	64.797101	61.681159	3.217391	0.000000
Dark	461.354839	445.741935	66.806452	88.387097	70.225806	74.645161	69.516129	76.161290	4.032258	0.064516
Dragon	474.375000	550.531250	83.312500	112.125000	86.375000	96.843750	88.843750	83.031250	3.875000	0.375000
Electric	363.500000	443.409091	59.795455	69.090909	66.295455	90.022727	73.704545	84.500000	3.272727	0.090909
Fairy	449.529412	413.176471	74.117647	61.529412	65.705882	78.529412	84.705882	48.588235	4.117647	0.058824
Fighting	363.851852	416.444444	69.851852	96.777778	65.925926	53.111111	64.703704	66.074074	3.370370	0.000000

resim 83

toplam kaç adet tür(type1) olduğunu bulalım

data["Type 1"].nunique()

```
18
```

Her türden kaç adet karakter olduğunu bulmak için,

data["Type 1"].value_counts()

```
Water       112
Normal       98
Grass        70
Bug          69
Psychic      57
Fire         52
Electric     44
Rock         44
Ground       32
Dragon       32
Ghost        32
Dark         31
```

```
Poison      28
Fighting    27
Steel       27
Ice         24
Fairy       17
Flying       4
Name: Type 1, dtype: int64
```